Pronósticos de empleo agrícola en Estados Unidos:
Una evaluación del poder predictivo mediante modelos de series de tiempo

Antonio Gutiérrez Arango*
Facultad de Economía, Universidad del Rosario, Colombia

Abril 2026

Resumen

Este trabajo evalúa si la incorporación de información sobre capital físico mejora la capacidad predictiva del empleo agrícola en Estados Unidos. Utilizando datos mensuales provenientes del Federal Reserve Bank of St. Louis (FRED) para el periodo 2000–2025, se estiman y comparan cinco modelos de pronóstico: un modelo naïve estacional, un modelo de suavizamiento Holt-Winters, y tres especificaciones SARIMA con diferentes conjuntos de regresores. La evaluación fuera de muestra se realiza sobre 36 observaciones mensuales (octubre de 2022 a septiembre de 2025) mediante el error cuadrático medio (RMSE), el error porcentual absoluto medio (MAPE), el coeficiente de Theil y la prueba de Diebold-Mariano. Los resultados muestran que el modelo SARIMA base, estimado únicamente sobre la dinámica interna del empleo agrícola, supera en precisión predictiva a todos los modelos que incorporan regresores externos, incluido el capital físico. La prueba de Diebold-Mariano confirma que esta superioridad es estadísticamente significativa frente al modelo completo.

Keywords: pronóstico, empleo agrícola, SARIMA, capital físico, Diebold-Mariano.

* *E-mail*: **antonio.gutierrez@urosario.edu.co**

Introducción

La producción agrícola en Estados Unidos se ha triplicado en los últimos 60 años, no obstante, el uso de mano de obra en el sector ha caído cerca de un 76 por ciento en el mismo periodo (USDA, 2022). Esta evidente divergencia se atribuye principalmente a un aumento continuo de la producción agrícola asociado a la acumulación de capital físico por parte de los agricultores, como resultado del desarrollo tecnológico y la transición hacia una producción más mecanizada. El aumento de la productividad a través de la mecanización en el campo se da a partir de dos principales mecanismos: i) la sustitución directa de trabajo por maquinaria; y ii) la incorporación de tecnologías complementarias que aumentan la productividad del trabajo. A través de ambas vías, los mecanismos de ajuste del mercado interactúan, afectando salarios, costos de producción y, en última instancia, precios y cantidades en el sector agrícola (Hamilton et al., 2020).

Adicionalmente, la evidencia histórica muestra que estos procesos han tenido efectos estructurales profundos sobre la economía. En el caso de Estados Unidos, la mecanización agrícola no solo redujo significativamente la demanda de trabajo en el sector, sino que también liberó mano de obra hacia actividades industriales y de servicios, contribuyendo al crecimiento económico agregado y a cambios en la estructura productiva (Steckel and White, 2012). Este proceso refleja el carácter de la mecanización como una tecnología intensiva en capital y ahorradora de trabajo, con efectos que trascienden el sector agrícola.

Por su parte, América Latina también se ha visto influenciada por estas dinámicas, aunque con una mayor heterogeneidad en su adopción. La evidencia reciente sugiere que el avance de la mecanización en la región ha contribuido a incrementos en la productividad agrícola, pero también ha estado asociado a procesos de transformación estructural, donde la reducción del empleo agrícola coexiste con una expansión de sectores no agrícolas. Sin embargo, este proceso no ha sido homogéneo ni automático, debido a limitaciones institucionales, tecnológicas y de acceso al capital que condicionan la velocidad de adopción tecnológica (Kerrigan, 2026). En este contexto, la mecanización no solo actúa como un motor de productividad, sino también como un determinante clave en la reasignación de recursos dentro de la economía.

En línea con esta evidencia, la literatura reciente ha documentado que la mecanización agrícola actúa como una tecnología ahorradora de trabajo que induce reasignaciones de empleo hacia sectores más productivos, generando efectos positivos sobre la productividad agregada. Por ejemplo, estudios empíricos muestran que incrementos en la mecanización están asociados con reducciones en la participación del empleo agrícola y aumentos en la actividad manufacturera, reflejando su papel en los procesos de cambio estructural (Kebede, 2024).

En este contexto, este trabajo busca identificar qué tan importante es la inclusión de información sobre capital físico para mejorar los pronósticos del empleo agrícola en Estados Unidos. Utilizando datos de la FRED, se estiman distintos modelos de series de tiempo y se evalúa su capacidad predictiva mediante ejercicios de comparación de pronósticos fuera de muestra. Para ello, se realiza primero una descripción detallada de los datos y su comportamiento, seguida de la discusión de la metodología. Posteriormente, se presentan y analizan los resultados de los modelos, y finalmente se exponen las conclusiones del estudio.

Datos

Los datos utilizados en este proyecto provienen del Federal Reserve Bank of St. Louis (FRED), una base de datos ampliamente utilizada en la literatura empírica por su consistencia, disponibilidad y estandarización de series macroeconómicas y sectoriales (FRED, 2026). Todas las series se encuentran en frecuencia mensual y cubren el periodo comprendido entre enero de 2000 y septiembre de 2025. La elección de esta frecuencia permite capturar dinámicas de corto plazo relevantes para el análisis de pronósticos, así como la interacción entre variables reales y de precios dentro del sector agrícola. Las cuatro series se presentan en la figura 1.

Nivel de empleo

La variable dependiente de este estudio corresponde al nivel de empleo en el sector agrícola de Estados Unidos. Esta serie proviene de la *Current Population Survey* (código FRED: LNU02034560) y mide el

número total de personas empleadas en actividades relacionadas con la agricultura, incluyendo producción primaria y actividades conexas. La serie está expresada en miles de personas y refleja tanto cambios estructurales de largo plazo como fluctuaciones cíclicas asociadas a condiciones económicas y estacionales del sector.

Capital físico

La variable que aproxima el capital físico corresponde al total de inventarios del sector de maquinaria agrícola y equipos relacionados (código FRED: A33ATI). Esta serie mide el valor monetario de los inventarios mantenidos por los fabricantes de maquinaria agrícola, lo cual funciona como un indicador indirecto del stock de capital disponible y de la dinámica de inversión en tecnología agrícola. Dado que la mecanización es un proceso intensivo en capital, variaciones en esta variable capturan cambios en la disponibilidad y acumulación de bienes de capital que potencialmente afectan la demanda de trabajo en el sector.

Controles

Con el fin de aislar el efecto del capital físico sobre el empleo agrícola, se incorporan dos variables de control que capturan condiciones de precios y costos en el sector:

1) **Precios agrícolas:** Se utiliza el índice de precios al productor para productos agrícolas (código FRED: WPU01), el cual mide la evolución de los precios de los bienes agrícolas en el nivel mayorista. Este indicador captura shocks de precios relevantes para la rentabilidad del sector, los cuales pueden influir tanto en decisiones de producción como en la demanda de trabajo.

2) **Salario mínimo agrícola:** Se emplea el salario mínimo federal para trabajadores agrícolas (código FRED: FEDMINFRMWG), medido en dólares por hora. Esta variable permite capturar cambios en los costos laborales, los cuales afectan directamente la demanda de trabajo y pueden incentivar procesos de sustitución hacia capital físico.

Metodología

El objetivo metodológico del trabajo es evaluar si la inclusión de información sobre capital físico mejora la capacidad predictiva del empleo agrícola. Para ello, la muestra se divide en dos subperiodos: un periodo inicial de estimación que abarca desde enero de 2000 hasta septiembre de 2022, con 273 observaciones mensuales, y un periodo de evaluación fuera de muestra que se extiende desde octubre de 2022 hasta septiembre de 2025, con 36 observaciones. Esta partición permite comparar el desempeño de los modelos en un contexto estrictamente fuera de muestra, condición necesaria para una evaluación rigurosa de la capacidad predictiva.

Análisis de integración

Como paso previo a la estimación, se verifica el orden de integración de cada serie mediante la prueba aumentada de Dickey-Fuller (ADF) (Hamilton, 1994). Esta prueba evalúa la hipótesis nula de existencia de raíz unitaria, de forma que su rechazo indica estacionariedad. Se aplica en tres formas para cada variable: sobre la serie en niveles, sobre la primera diferencia regular y sobre la primera diferencia estacional. La inclusión de término de tendencia en todas las especificaciones sigue la práctica estándar para series económicas con tendencia determinista. Los resultados se presentan en la tabla 1 y orientan la selección del orden de diferenciación en los modelos SARIMA.

Identificación del modelo SARIMA

La estructura ARIMA estacional se identifica a partir del análisis conjunto de las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) calculadas sobre la serie doblemente diferenciada, $\Delta\Delta_{12}\ln(\text{empleo})$, así como mediante un procedimiento de selección automática por criterio de información de Akaike (AIC). En una primera etapa, la inspección visual de las funciones (ver figura 2) permite identificar los órdenes candidatos para los componentes regular y estacional. En una segunda etapa, se evalúan sistemáticamente todas las combinaciones $p, q \in \{0, 1, 2\}$ y $P, Q \in \{0, 1\}$ bajo diferenciación $(d, D) = (1, 1)$ con periodo estacional $s = 12$, seleccionando como especificación de referencia el modelo

SARIMA$(1,1,1)(1,1,1)_{12}$, el cual presenta un equilibrio adecuado entre ajuste y parsimonia, en línea con la evidencia de los correlogramas.

Modelos de pronóstico

Sobre la base de la especificación identificada, se estiman cinco modelos cuya capacidad predictiva se evalúa en el periodo fuera de muestra:

i) **Naïve estacional:** Asigna como pronóstico el valor observado en el mismo mes del año anterior, $\hat{y}_t = y_{t-12}$. Constituye el benchmark mínimo de referencia.

ii) **Holt-Winters:** Implementa el método de suavizamiento exponencial con componente estacional aditivo sobre la serie en logaritmos (Holt, 2004), lo que equivale a una especificación multiplicativa en niveles.

iii) **SARIMA base:** Modelo SARIMA$(1,1,1)(1,1,1)_{12}$ estimado únicamente sobre ln(empleo), sin regresores externos.

iv) **SARIMA con controles:** Extiende el modelo base incorporando como regresores exógenos el logaritmo del índice de precios al productor agrícola y el logaritmo del salario mínimo para trabajadores agrícolas.

v) **SARIMA completo:** Añade al modelo anterior el logaritmo del inventario de maquinaria agrícola en niveles contemporáneos y con dos rezagos, con el fin de capturar el efecto diferido de la acumulación de capital sobre el empleo.

Todos los modelos se estiman exclusivamente sobre el periodo de entrenamiento. Los pronósticos fuera de muestra se generan utilizando los valores observados de los regresores en el periodo de evaluación, de forma que la comparación refleja únicamente diferencias en la especificación del modelo y no en la disponibilidad de información.

Métricas de evaluación

La comparación entre modelos se realiza a partir de métricas estándar de precisión predictiva (Hyndman and Athanasopoulos, 2018). En particular, se utiliza el error cuadrático medio:

$$\text{RMSE} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(y_t - \hat{y}_t)^2}$$

así como el error porcentual absoluto medio:

$$\text{MAPE} = \frac{1}{T}\sum_{t=1}^{T}\left|\frac{y_t - \hat{y}_t}{y_t}\right|$$

y el coeficiente de desigualdad de Theil U, definido como el cociente entre el RMSE del modelo y el RMSE del modelo naïve. Valores de $U < 1$ indican que el modelo supera al benchmark, mientras que $U = 1$ implica desempeño equivalente al naïve. Estas métricas se calculan únicamente sobre el periodo de evaluación fuera de muestra y se expresan en niveles originales de la variable dependiente (miles de personas), garantizando comparabilidad entre modelos.

Test de Diebold-Mariano

Finalmente, se implementa la prueba de Diebold-Mariano para contrastar formalmente si las diferencias en precisión predictiva entre modelos son estadísticamente significativas. Esta prueba se basa en la serie de diferencias de pérdidas definida como:

$$d_t = L(e_{1t}) - L(e_{2t})$$

donde $L(\cdot)$ es la función de pérdida cuadrática $L(e) = e^2$, y evalúa la hipótesis nula de igual capacidad predictiva entre dos modelos (Diebold and Mariano, 1995). El estadístico de prueba se obtiene como el estadístico t de la regresión de d_t sobre una constante con errores estándar Newey-West, utilizando $h = \lfloor T^{1/3} \rfloor$ rezagos de acuerdo con la recomendación de Harvey et al. (1997). Se realizan tres comparaciones: entre el SARIMA base y el SARIMA con controles (A), entre el SARIMA base y el SARIMA completo (B), y entre el SARIMA con controles y el SARIMA completo (C), siendo esta última la comparación

central del trabajo. De esta forma, se determina si la inclusión del capital físico aporta información relevante para mejorar los pronósticos más allá de los modelos que solo consideran la dinámica interna de la serie y los controles de mercado.

Análisis de resultados

Esta sección presenta los resultados de los modelos estimados y la evaluación de su capacidad predictiva en el periodo fuera de muestra. El análisis sigue el orden metodológico planteado: primero se discuten los coeficientes estimados de los tres modelos SARIMA, luego las métricas de precisión predictiva y finalmente los resultados del test de Diebold-Mariano.

Identificación y selección del modelo SARIMA

La selección de la especificación SARIMA$(1,1,1)(1,1,1)_{12}$ resulta de combinar la evidencia de las pruebas de raíz unitaria, la inspección de los correlogramas y la búsqueda automática por AIC.

- **Órdenes de diferenciación** ($d = 1, D = 1$)**.** La prueba ADF no rechaza la raíz unitaria en niveles ($p = 0{,}545$) pero sí sobre la primera diferencia regular ($p < 0{,}001$), estableciendo $d = 1$. La ACF y PACF de $\Delta \ln(\text{empleo})$ (ver figura 2) revelan spikes significativos en el rezago 12 (ACF $\approx -0{,}40$, PACF $\approx -0{,}30$), indicando estacionalidad no removida. Esto justifica una diferencia estacional adicional, $D = 1$.
- **Órdenes regulares y estacionales** (p, q, P, Q)**.** Sobre la serie doblemente diferenciada $\Delta\Delta_{12} \ln(\text{empleo})$ (ver figura 2) la ACF presenta un corte abrupto tras el rezago 1 y un spike negativo en el rezago 12, mientras que la PACF muestra decaimiento gradual en ambas frecuencias. Este patrón es consistente con componentes MA(1) en la parte regular y MA(1) estacional, con un término AR(1) adicional para capturar la persistencia de corto plazo visible en la PACF. Esto sugiere $p = q = 1$ y $P = Q = 1$.
- **Confirmación por AIC y BIC.** La búsqueda sobre todas las combinaciones $p, q \in \{0, 1, 2\}$ y $P, Q \in \{0, 1\}$ sitúa al SARIMA$(2,1,2)(1,1,1)_{12}$ como el modelo de menor AIC ($-927{,}06$), pero la diferencia respecto al SARIMA$(1,1,1)(1,1,1)_{12}$ (AIC $= -924{,}20$) es inferior a tres unidades. El BIC, que penaliza más severamente la complejidad del modelo, revierte directamente este ordenamiento: el SARIMA$(1,1,1)(1,1,1)_{12}$ obtiene un BIC de $-902{,}84$, inferior al del modelo de mayor orden ($-902{,}13$), favoreciendo la especificación más parsimoniosa. Dado que ambos criterios apuntan en la misma dirección —AIC por margen estrecho y BIC de forma definitiva— se adopta el SARIMA$(1,1,1)(1,1,1)_{12}$ como modelo de referencia.

Coeficientes estimados

La **tabla 2** reporta los coeficientes de los tres modelos SARIMA estimados sobre el periodo de entrenamiento. En el **modelo base**, todos los componentes ARMA son estadísticamente significativos al 1 %: el término autorregresivo AR(1) es 0,571, el de medias móviles MA(1) es $-0{,}907$, el componente estacional SAR(1) es 0,222 (significativo al 5 %) y el SMA(1) estacional es $-0{,}930$. Este patrón confirma la presencia de dinámica de corto plazo y de corrección estacional mediante medias móviles, consistente con la estructura identificada en los correlogramas de la **figura 2**.

La incorporación de controles en el **SARIMA con controles** altera sustancialmente la dinámica estimada: los términos AR(1) y MA(1) pierden significancia estadística, posiblemente por colinealidad entre los regresores externos y la estructura ARMA. El índice de precios al productor agrícola presenta un coeficiente positivo marginalmente significativo (0,136, $p = 0{,}092$), mientras que el salario mínimo no resulta significativo ($-0{,}111$, $p = 0{,}771$).

En el **SARIMA completo**, ninguno de los coeficientes asociados al capital físico alcanza significancia estadística: el efecto contemporáneo de los inventarios de maquinaria es 0,125 ($p = 0{,}183$), el primer rezago $-0{,}081$ ($p = 0{,}385$) y el segundo rezago $-0{,}132$ ($p = 0{,}151$). Este resultado anticipa el hallazgo central del trabajo: el capital físico, aproximado por los inventarios de maquinaria, no aporta información predictiva estadísticamente relevante en el corto plazo.

Métricas de precisión predictiva

La **tabla 3** presenta las métricas de evaluación calculadas sobre las 36 observaciones del periodo fuera de muestra. El modelo naïve estacional constituye el benchmark mínimo con un RMSE de 94,9 miles de personas y un MAPE de 3,4 %. El modelo Holt-Winters mejora marginalmente este resultado (RMSE = 88,7, $U = 0{,}935$), lo que implica una reducción del error del 6,5 % respecto al benchmark. El **SARIMA base** obtiene el mejor desempeño entre todos los modelos comparados: RMSE = 72,7, MAPE = 2,5 % y $U = 0{,}767$, representando una reducción del error cuadrático medio del 23 % frente al naïve. De manera llamativa, la incorporación de regresores externos deteriora sistemáticamente la precisión predictiva: el SARIMA con controles eleva el RMSE a 77,0 ($U = 0{,}812$) y el SARIMA completo a 75,8 ($U = 0{,}799$). Este patrón, visible en la **figura 3**, indica que la información adicional introduce ruido de estimación que supera su valor predictivo en el horizonte de evaluación considerado.

Test de Diebold-Mariano

La **tabla 4** reporta los resultados de las tres comparaciones formales de precisión predictiva. En la comparación **A** (SARIMA base vs. SARIMA con controles), el estadístico DM es $-1{,}331$ ($p = 0{,}192$), sin evidencia de diferencias significativas. La media negativa de d_t ($-639{,}04$) indica que el modelo base genera errores menores en promedio, aunque la diferencia no alcanza el umbral de significancia convencional. La comparación **B** (SARIMA base vs. SARIMA completo) arroja el resultado más relevante del trabajo: el estadístico DM es $-2{,}426$ ($p = 0{,}021$), rechazando la hipótesis nula de igual precisión al nivel del 5 %. La media negativa de d_t ($-453{,}58$) confirma que el SARIMA base genera consistentemente errores cuadráticos menores que el modelo que incorpora capital físico. La comparación **C** (SARIMA con controles vs. SARIMA completo) no arroja diferencias significativas ($p = 0{,}668$), lo que sugiere que la adición específica del capital físico, y no la de los controles en general, es la que deteriora el pronóstico de forma estadísticamente significativa.

Diagnóstico de residuos

Con el fin de validar la especificación del modelo, se analizan los residuos del SARIMA completo (figura 4). La prueba de Ljung-Box arroja un estadístico $Q = 31{,}4$ con $p = 0{,}143$ para 24 rezagos, lo que no permite rechazar la hipótesis nula de ruido blanco. Este resultado confirma un comportamiento adecuado de los residuos, acorde a los supuesto de predicción (Levendis, 2018).

Conclusiones

Los resultados de este trabajo indican que la inclusión de información sobre capital físico no mejora la capacidad predictiva del empleo agrícola en Estados Unidos. El modelo SARIMA$(1,1,1)(1,1,1)_{12}$ estimado únicamente sobre la dinámica interna de la serie supera en precisión a todas las especificaciones que incorporan regresores externos, con una reducción del error cuadrático medio del 23 % frente al benchmark naïve.

Esta conclusión se sostiene en dos resultados complementarios. Primero, los coeficientes asociados a los inventarios de maquinaria agrícola no resultan estadísticamente significativos en ninguna de sus formas (nivel contemporáneo, primer rezago ni segundo rezago) lo que sugiere que esta variable no contiene información relevante para para pronosticar el empleo agrícola. Segundo, la prueba de Diebold-Mariano confirma que la superioridad del SARIMA base frente al modelo completo es estadísticamente significativa al 5 % (DM $= -2{,}426$, $p = 0{,}021$), descartando que la diferencia en precisión sea producto del azar.

Una interpretación plausible es que los efectos de la mecanización sobre el empleo agrícola operan en horizontes de tiempo más largos que los contemplados en este ejercicio, de forma que los inventarios de maquinaria no logran anticipar los movimientos mensuales del empleo. En este sentido, la estructura estacional y de persistencia propia de la serie resulta suficiente para capturar la dinámica de corto plazo, y la adición de regresores introduce ruido de estimación que deteriora la precisión fuera de muestra.

Tablas y Figuras

Figura 1: Series del modelo — EE.UU.

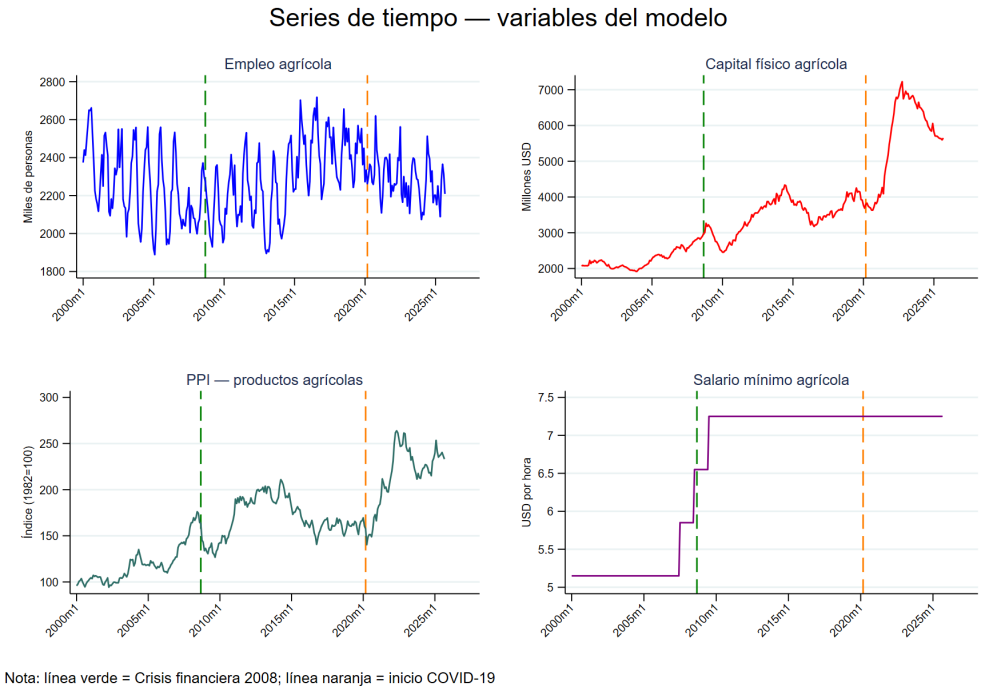

Nota: Línea verde = crisis financiera 2008; línea naranja = inicio COVID-19.

Figura 2: Funciones de autocorrelación — identificación SARIMA

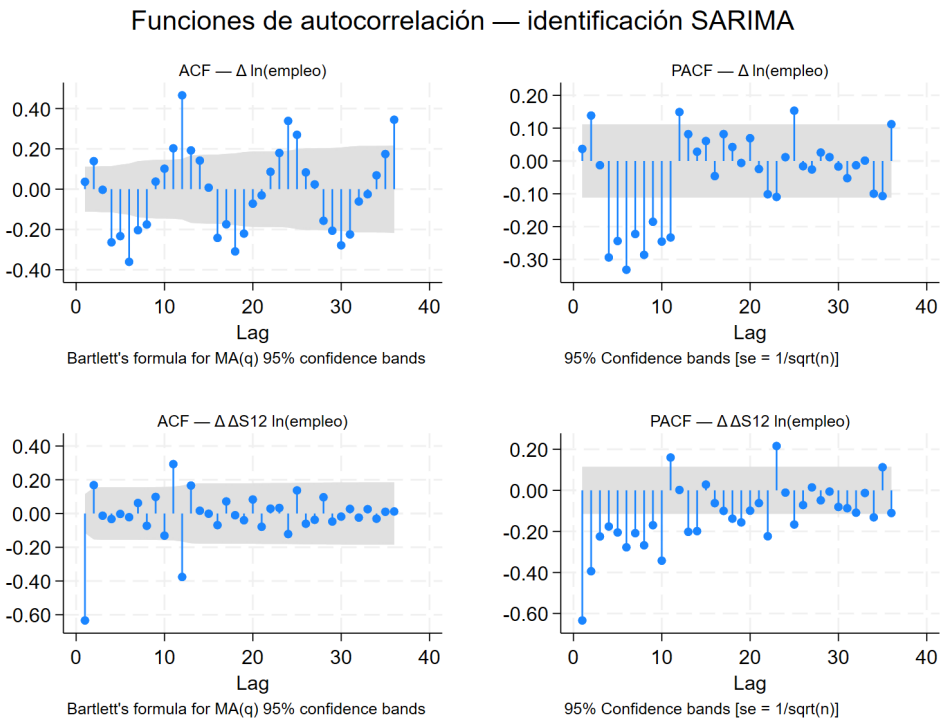

Nota: Fila superior: $\Delta \ln(\text{empleo})$. Fila inferior: $\Delta\Delta_{12} \ln(\text{empleo})$. Bandas al 95 %. 36 rezagos.

Tabla 1: Pruebas ADF — orden de integración

	Niveles		Δ regular		Δ estacional	
Variable	Estadíst.	p-val	Estadíst.	p-val	Estadíst.	Conclusión
ln(empleo agr.)	−2,102	0,545	−7,452***	0,000	−7,716***	$I(1)$
ln(inv. maq.)	−3,053	0,118	−4,482***	0,002	−6,729***	$I(1)$
ln(PPI agr.)	−2,892	0,165	−4,541***	0,001	−6,520***	$I(1)$
ln(sal. mín.)	−2,024	0,588	−2,459	0,349	−4,631***	$I(1)$

VC con tendencia: 1 % = −3,99, 5 % = −3,43, 10 % = −3,13.
***$p < 0{,}01$, **$p < 0{,}05$, *$p < 0{,}10$. H_0: la serie tiene raíz unitaria.

Tabla 2: Resultados modelos SARIMA

	(1) SARIMA base	(2) SARIMA + controles	(3) SARIMA completo
Variables explicativas			
ln_emp_agr			
DS12.ln_ppi_farm		0.136*	0.039
		(0.080)	(0.066)
DS12.ln_salario_min		-0.111	-0.035
		(0.383)	(0.200)
DS12.ln_inv_manuf			0.125
			(0.094)
DS12.ln_inv_manuf (L1)			-0.081
			(0.093)
DS12.ln_inv_manuf (L2)			-0.132
			(0.092)
Constante	0.000	0.000	0.000
	(0.000)	(0.000)	(0.000)
Componente ARMA(1,1)			
AR(1)	0.571***	-0.185	0.575***
	(0.083)	(0.229)	(0.085)
MA(1)	-0.907***	-0.118	-0.914***
	(0.044)	(0.239)	(0.046)
Componente estacional ARMA(1,1) (12)			
AR(12)	0.222**	0.205**	0.234***
	(0.086)	(0.089)	(0.088)
MA(12)	-0.930***	-0.919***	-0.922***
	(0.088)	(0.084)	(0.086)
Varianza del error			
σ	0.038***	0.040***	0.038***
	(0.002)	(0.002)	(0.002)
Estadísticos			
Observaciones	260	260	258
AIC	-924.20	-906.88	-912.45
BIC	-902.84	-878.40	-873.36
Log-likelihood	468.10	461.44	467.22

Notas: Errores estándar entre paréntesis. *$p < 0{,}10$, **$p < 0{,}05$, ***$p < 0{,}01$.

Figura 3: Pronósticos fuera de muestra — comparación de modelos

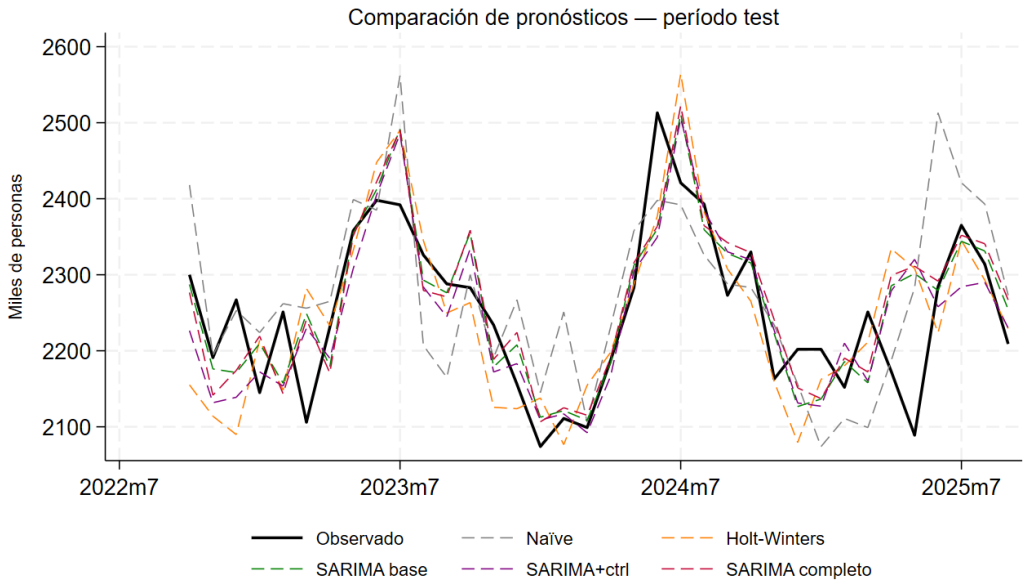

Nota: Periodo de evaluación: 2022m10–2025m9 (36 obs.). Línea negra: valores observados.

Tabla 3: Métricas de precisión predictiva — periodo fuera de muestra

Modelo	RMSE	MAPE (%)	Theil U
Naïve estacional	94.862	3.384	1.000
Holt-Winters	88.712	3.022	0.935
SARIMA base	**72.717**	**2.477**	**0.767**
SARIMA + controles	76.986	2.706	0.812
SARIMA completo	75.771	2.657	0.799

RMSE en miles de personas. $U = \text{RMSE}_{\text{modelo}}/\text{RMSE}_{\text{naïve}}$. En negrita el mejor modelo.

Tabla 4: Test de Diebold-Mariano

	Comparación	Media d_t	DM stat	p-valor	Conclusión
A	Base vs. +Controles	−639,04	−1,331	0,192	Sin diferencia sig.
B	Base vs. Completo	−453,58	−2,426**	0,021	Modelo base mejor
C	+Controles vs. Completo	185,46	0,433	0,668	Sin diferencia sig.

$d_t = e_{1t}^2 - e_{2t}^2$. Errores Newey-West (3 rezagos). H_0: igual precisión predictiva.
$^{***}p < 0{,}01$, $^{**}p < 0{,}05$, $^{*}p < 0{,}10$. Observaciones test: 36.

Figura 4: Residuos — modelo SARIMA completo

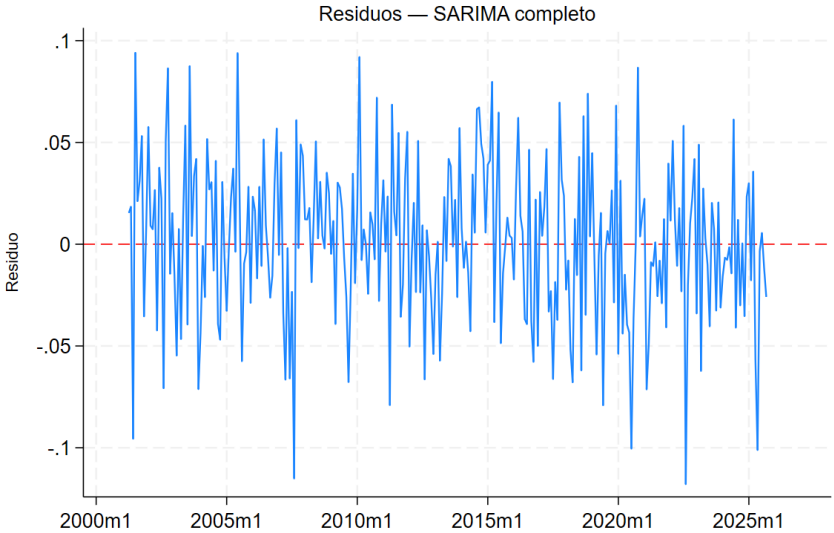

Nota: Prueba de Portmanteau: $Q = 31{,}4$, $\mathrm{p} = 0{,}143$ (24 rezagos). No se rechaza ruido blanco.

Referencias

Diebold, F. X. and R. S. Mariano (1995). Comparing predictive accuracy. *Journal of Business and Economic Statistics*@(3), 253–263.

FRED (2026). Fred: Federal reserve economic data. https://fred.stlouisfed.org/. Accessed: 2026-04-06.

Hamilton, J. D. (1994). *Time Series Analysis.* Princeton University Press.

Hamilton, S. F., T. J. Richards, and A. P. Shafran (2020). The impact of mechanization on agricultural markets: Evidence and implications. *Annual Review of Resource Economics 12, 123–145.*

Harvey, D., S. Leybourne, and P. Newbold (1997). Testing the equality of prediction mean squared errors. International Journal of Forecasting*@(2), 281–291.*

Holt, C. C. (2004). Forecasting seasonals and trends by exponentially weighted moving averages. International Journal of Forecasting*@(1), 5–10.*

Hyndman, R. J. and G. Athanasopoulos (2018). Forecasting: Principles and Practice *(2nd ed.). Melbourne, Australia: OTexts.*

Kebede, H. (2024). Agricultural mechanization and structural change: Evidence from china. Working paper.

Kerrigan, G. (2026). Seminario sobre transformación estructural y mecanización agrícola en américa latina. Presentación de seminario.

Levendis, J. D. (2018). Time Series Econometrics: Learning Through Replication. *Cham: Springer.*

Steckel, R. H. and W. J. White (2012). Engines of growth: Farm tractors and twentieth-century u.s. economic welfare. NBER Working Paper 17879, National Bureau of Economic Research.

USDA (2022). Agricultural productivity in the united states. https://www.ers.usda.gov/data-products/agricultural-productivity-in-the-us/. Accessed: 2026-04-06.