

Pronósticos del empleo agrícola en Estados Unidos

Una comparación extendida entre modelos univariados, multivariados y de alta dimensión

Antonio Gutiérrez Arango

Facultad de Economía, Universidad del Rosario, Colombia

Mayo 2026

Resumen

Este trabajo extiende el análisis previo sobre pronósticos del empleo agrícola en Estados Unidos incorporando tres enfoques adicionales: un modelo vectorial de corrección de errores (VECM), que evalúa la relación de largo plazo entre empleo y capital físico; un modelo de selección de variables mediante el procedimiento *One Covariate at a Time, Multiple Testing* (OCMT) de Chudik, Kapetanios y Pesaran (2018), con un conjunto activo de 15 variables macroeconómicas de alta frecuencia; y un ensemble ponderado siguiendo el Método B de Granger y Ramanathan (1984). Utilizando datos mensuales del FRED para el período 2000–2025 y un horizonte de evaluación de 36 observaciones fuera de muestra, comprendido entre octubre de 2022 y septiembre de 2025, se comparan ocho modelos mediante RMSE, MAPE, coeficiente de Theil U y la prueba de Diebold y Mariano (1995). Todos los pronósticos en escala logarítmica se corrigen por sesgo de retransformación siguiendo a Beauchamp y Olson (1973). Los resultados confirman que el modelo SARIMA(1,1,1)(1,1,1)₁₂ base, estimado únicamente sobre la dinámica interna de la serie, sigue siendo el mejor predictor, con un RMSE de 72.97 miles de personas y un Theil U de 0.769. El procedimiento OCMT no seleccionó ningún predictor externo, corroborando la suficiencia informacional del modelo univariado. El VECM y el ensemble ponderado no lograron superar al naïve estacional, lo que sugiere que la complejidad adicional no aporta valor predictivo en el horizonte mensual considerado.

Palabras clave: pronóstico, empleo agrícola, SARIMA, VECM, OCMT, combinación de pronósticos, Diebold-Mariano.

1. Introducción

La producción agrícola en Estados Unidos se ha triplicado en los últimos 60 años, mientras que el empleo en el sector ha caído cerca de un 76 por ciento en el mismo período (USDA Economic Research Service 2022). Esta divergencia refleja la acumulación sostenida de capital físico y la adopción de tecnologías ahorradoras de trabajo. En particular, la mecanización actúa tanto a través de la sustitución directa de mano de obra por maquinaria como mediante la incorporación de tecnologías complementarias que elevan la productividad del trabajo existente (S. F. Hamilton, Richards y Shafran 2020).

En este contexto, la capacidad de pronosticar con precisión el nivel de empleo agrícola resulta relevante para tres dimensiones principales: la planificación del mercado laboral rural; la asignación eficiente de recursos públicos; y el diseño de políticas de reconversión productiva.

Un trabajo previo (Gutiérrez Arango 2026) evaluó si la incorporación de información sobre capital físico, medida a través de los inventarios de maquinaria agrícola, mejora la capacidad predictiva del empleo agrícola. Comparando cinco modelos con datos mensuales del FRED para el período 2000–2025, ese análisis mostró que el modelo SARIMA base, estimado exclusivamente sobre la dinámica interna de la serie, supera en precisión predictiva a todos los modelos que incorporan regresores externos, con una reducción del RMSE del 23 % frente al naïve estacional. La prueba de Diebold-Mariano confirmó que esta superioridad es estadísticamente significativa al 5 %.

El presente trabajo extiende ese análisis hacia una comparación más amplia y metodológicamente diversa. Para ello, se incorporan tres modelos adicionales: un VECM bivariado que recoge la relación de largo plazo entre empleo y capital; un modelo con selección de variables mediante OCMT sobre un conjunto de 15 indicadores macroeconómicos; y un ensemble ponderado que combina los pronósticos de los mejores modelos individuales.

La pregunta central del documento es si alguno de estos enfoques más complejos logra mejorar el pronóstico frente al SARIMA base. En todos los casos, los pronósticos en logaritmos se convierten a niveles aplicando la corrección por sesgo de retransformación de Beauchamp y Olson (1973), lo que garantiza comparabilidad en la escala original de la variable dependiente.

2. Datos

Los datos provienen del Federal Reserve Bank of St. Louis (FRED) y cubren el período enero de 2000 a septiembre de 2025 en frecuencia mensual, para un total de 309 observaciones (Federal Reserve Bank of St. Louis 2026). La muestra se divide de la siguiente manera:

- **Período de entrenamiento:** enero de 2000 – septiembre de 2022, con $T = 273$ observaciones.
- **Período de evaluación fuera de muestra:** octubre de 2022 – septiembre de 2025, con $h = 36$ observaciones.

2.1. Variable dependiente

El nivel de empleo agrícola corresponde a la serie LNU02034560 de la *Current Population Survey*, expresada en miles de personas.

Durante el período muestral, la serie registra una media de 2,278 miles de personas, con un valor mínimo de 1,889 miles y un valor máximo de 2,718 miles. Estos valores muestran que, aunque el empleo agrícola mantiene una escala relativamente estable, presenta variaciones importantes alrededor de su nivel promedio, consistentes con su patrón estacional y con la tendencia decreciente observada en el largo plazo.

La serie exhibe un fuerte patrón estacional, con picos en verano y valles en invierno. Además, presenta una tendencia decreciente de largo plazo y un quiebre estructural asociado al inicio de la pandemia de COVID-19 en marzo de 2020.

2.2. Variables exógenas para modelos SARIMA

Se emplean las mismas variables del análisis anterior:

- Índice de precios al productor para productos agrícolas (WPU01).
- Salario mínimo federal para trabajadores agrícolas (FEDMINFRMWG).
- Inventarios de maquinaria agrícola (A33ATI), como aproximación al stock de capital físico.

Las cuatro series originales resultan integradas de orden uno, $I(1)$, según la prueba aumentada de Dickey-Fuller (ADF) con tendencia. En particular, no se rechaza la hipótesis nula de raíz unitaria en niveles, pero sí se rechaza en primera diferencia regular y estacional, como se reporta en la Tabla 3 del Anexo.

2.3. Conjunto activo para OCMT

Para el procedimiento OCMT se construye un panel de 15 variables candidatas provenientes de FRED, agrupadas en seis categorías principales: mercado laboral, con PAYEMS y UNRATE; precios macroeconómicos, con CPIAUCSL y PPIACO; condiciones monetarias y financieras, con FEDFUNDS, GS10, T10Y2Y y M2SL; insumos energéticos, representados por DCOILWTICO; actividad real, con INDPRO, HOUST y RSXFS; y capital físico, aproximado mediante A33ATI.

Todas las variables se transforman a logaritmos, salvo las tasas, y se utilizan en forma de rezago 1 de la primera diferencia. Esta construcción garantiza que los predictores de t solo empleen información observable hasta $t - 1$, condición necesaria para la validez del pronóstico fuera de muestra.

Para el VECM se utilizan únicamente las series de empleo agrícola e inventarios de maquinaria, ambas en logaritmos, dada su integración de orden uno confirmada.

2.4. Corrección por sesgo de retransformación

Todas las series empleadas en modelos con variables logarítmicas se expresan en logaritmos naturales durante la estimación. Los pronósticos resultantes se retransforman a niveles mediante la corrección lognormal de Beauchamp y Olson (1973):

$$\hat{y}_t^{\text{BO}} = \exp(\hat{y}_t^{\text{ln}}) \times \exp\left(\frac{\hat{\sigma}^2}{2}\right), \quad (1)$$

donde $\hat{\sigma}^2$ es la varianza residual estimada en escala logarítmica sobre la muestra de entrenamiento.

Este ajuste elimina el sesgo sistemático de subestimación que introduce la exponenciación simple y permite comparar los pronósticos directamente con el nivel observado del empleo.

3. Metodología

3.1. Modelos de pronóstico

Se estiman ocho modelos, ordenados de menor a mayor complejidad. La estrategia de comparación permite evaluar si la incorporación de información adicional o de estructuras multivariadas mejora la precisión predictiva frente a un modelo univariado parsimonioso.

- **Modelo 1: Naïve estacional.**

El modelo naïve estacional asigna como pronóstico el valor observado del mismo mes del año anterior:

$$\hat{y}_t = y_{t-12}.$$

Este modelo constituye el *benchmark* mínimo de referencia para evaluar la utilidad predictiva de los demás enfoques.

- **Modelo 2: Holt-Winters multiplicativo.**

El segundo modelo corresponde a un suavizamiento exponencial aditivo aplicado sobre $\ln y_t$, equivalente a un modelo multiplicativo en niveles (Holt 2004). Los parámetros de nivel, tendencia y estacionalidad se optimizan minimizando la suma de errores cuadrados sobre la muestra de entrenamiento.

- **Modelos 3–5: SARIMA.**

La especificación SARIMA(1, 1, 1)(1, 1, 1)₁₂ se identifica combinando el análisis de las funciones ACF y PACF de $\Delta\Delta_{12} \ln y_t$ con una búsqueda exhaustiva por criterios de información AIC y BIC sobre el espacio $p, q \in \{0, 1, 2\}$ y $P, Q \in \{0, 1\}$. El resultado favorece la especificación $p = q = P = Q = 1$ por parsimonia, de acuerdo con el criterio BIC.

Se estiman tres variantes del modelo SARIMA:

- **SARIMA base:** estimado únicamente sobre $\ln y_t$.
- **SARIMA con controles:** incorpora el PPI agrícola y el salario mínimo como regresores exógenos.
- **SARIMA completo:** incorpora adicionalmente el inventario de maquinaria agrícola en su valor contemporáneo y con dos rezagos (J. D. Hamilton 1994).

Todos los modelos SARIMA se estiman exclusivamente sobre la muestra de entrenamiento.

■ **Modelo 6: VECM.**

La prueba de cointegración de Johansen (Levendis 2018) revela un vector de cointegración entre $\ln(\text{empleo})$ y $\ln(\text{inventarios})$ al 5 %, de acuerdo con el estadístico de traza para $r = 1$.

A partir de este resultado, se estima un VECM bivariado con tendencia constante en el vector de cointegración y rezago óptimo $p = 4$, seleccionado mediante el criterio de Schwarz-Bayes con `varsoc`. El pronóstico dinámico se genera para los 36 períodos del horizonte de evaluación mediante `fcast compute`. La varianza residual de la ecuación de empleo se emplea para aplicar la corrección Beauchamp-Olson descrita en la ecuación 1.

■ **Modelo 7: OCMT-SARIMA.**

Se aplica el procedimiento *One Covariate at a Time, Multiple Testing* de Chudik, Kapetanios y Pesaran (2018), en su versión de Stata desarrollada por Núñez y Otero (2021). La variable dependiente es $\Delta\Delta_{12} \ln y_t$, mientras que el conjunto activo contiene el rezago 1 de la primera diferencia de cada una de las 15 variables candidatas.

Las variables preseleccionadas, `zvar`, corresponden a los rezagos 1–4 de la variable dependiente. Se emplean los parámetros $\delta = 1$, $\delta^* = 2$ y $p = 5\%$, siguiendo a Chudik, Kapetanios y Pesaran (2018).

■ **Modelo 8: Ensemble ponderado.**

El ensemble ponderado sigue el Método B de Granger y Ramanathan (1984). Los pesos se estiman por mínimos cuadrados, restringiendo la suma a la unidad. La regresión se efectúa sobre la muestra de entrenamiento usando los valores ajustados *in-sample* de cada modelo. Posteriormente, el pronóstico combinado para el período de evaluación se obtiene aplicando los pesos estimados a los pronósticos fuera de muestra.

El ensemble incluye los modelos Holt-Winters, SARIMA base, SARIMA con controles y VECM. El modelo OCMT fue excluido por colinealidad perfecta con el SARIMA base, resultado que anticipa el hallazgo principal de la sección de resultados.

3.2. Métricas de evaluación

La comparación entre modelos se realiza sobre las 36 observaciones del período de prueba. Las métricas se calculan en niveles, expresados en miles de personas.

Se emplean tres medidas principales:

- **RMSE:**

$$\text{RMSE} = \sqrt{T^{-1} \sum_{t=1}^T e_t^2}.$$

- **MAPE:**

$$\text{MAPE} = T^{-1} \sum_{t=1}^T \left| \frac{e_t}{y_t} \right| \times 100.$$

- **Coeficiente de Theil:**

$$U = \frac{\text{RMSE}_m}{\text{RMSE}_{\text{naïve}}}.$$

Un valor $U < 1$ indica superioridad del modelo evaluado frente al *benchmark* naïve estacional (Hyndman y Athanasopoulos 2018).

Además, se emplea la prueba de Diebold y Mariano (1995) para contrastar formalmente la igualdad de precisión predictiva entre pares de modelos. Se utilizan errores estándar Newey-West y $h = \lfloor T^{1/3} \rfloor = 3$ rezagos, siguiendo la recomendación de Harvey, Leybourne y Newbold (1997). La función de pérdida es cuadrática:

$$d_t = e_{1t}^2 - e_{2t}^2.$$

4. Análisis de resultados

4.1. Identificación y pruebas preliminares

Las pruebas ADF confirman que las cuatro series originales son $I(1)$. En particular, no se rechaza la raíz unitaria en niveles para ninguna variable, con valores p entre 0.118 y 0.588, pero sí se rechaza en primera diferencia regular y estacional al nivel del 1 %. Estos resultados se reportan en la Tabla 3 del Anexo.

La especificación SARIMA(1, 1, 1)(1, 1, 1)₁₂ queda justificada por dos elementos: el patrón observado en los correlogramas de $\Delta\Delta_{12} \ln y_t$ y la selección por BIC entre las especificaciones candidatas.

La prueba de Johansen confirma la existencia de un vector de cointegración entre $\ln(\text{empleo})$ y $\ln(\text{inventarios})$ al nivel del 5 %, lo que justifica el uso del VECM frente al VAR en diferencias.

Este resultado es consistente con la narrativa económica: existe una relación de equilibrio de largo plazo entre la demanda de trabajo agrícola y el stock de capital físico, aunque dicha

relación no sea necesariamente útil para pronosticar movimientos de corto plazo.

Por su parte, el procedimiento OCMT no seleccionó ninguna variable del conjunto activo como predictor externo relevante de $\Delta\Delta_{12} \ln y_t$. En consecuencia, el modelo OCMT-SARIMA es matemáticamente idéntico al SARIMA base.

4.2. Métricas de precisión predictiva

La Tabla 1 presenta las métricas de evaluación para los ocho modelos, calculadas sobre las 36 observaciones fuera de muestra con corrección Beauchamp-Olson. El modelo naïve estacional establece el *benchmark*, con un RMSE de 94.9 miles de personas y un MAPE de 3.4 %.

Tabla 1: Métricas de precisión predictiva: período fuera de muestra con corrección B-O

Modelo	RMSE	MAPE (%)	Theil U
Naïve estacional	94.862	3.384	1.000
Holt-Winters	212.605	8.834	2.241
SARIMA base	72.967	2.479	0.769
SARIMA + controles	76.933	2.699	0.811
SARIMA completo	76.097	2.669	0.802
VAR/VECM	150.390	5.918	1.585
OCMT-SARIMA	72.967	2.479	0.769
Ensemble G-R B	116.041	4.395	1.223

Nota: RMSE en miles de personas. $U = \text{RMSE}_m / \text{RMSE}_{\text{naïve}}$. Corrección B-O: $\hat{y}^{\text{BO}} = \exp(\hat{y}^{\text{ln}}) \times \exp(\hat{\sigma}^2/2)$ (Beauchamp y Olson 1973). OCMT-SARIMA es idéntico al SARIMA base, dado que ninguna variable externa fue seleccionada. En negrita se reporta el mejor modelo.

El SARIMA base obtiene el menor RMSE y MAPE entre todos los modelos, con un Theil $U = 0,769$, lo que indica una reducción del error del 23.1 % frente al naïve estacional.

El SARIMA con controles y el SARIMA completo presentan un desempeño ligeramente inferior, reiterando el hallazgo del análisis anterior: los regresores externos, incluyendo el capital físico, no mejoran la capacidad predictiva en el horizonte mensual analizado (Gutiérrez Arango 2026).

Los modelos con mayor complejidad estructural muestran un desempeño notablemente peor. El VECM obtiene un RMSE de 150.4 y un Theil $U = 1,585$, es decir, su error es un 58 % superior al del naïve. Este resultado sugiere que, si bien existe una relación de cointegración de largo plazo entre empleo e inventarios, dicha relación no aporta información útil para pronosticar fluctuaciones mensuales en el horizonte de 36 períodos considerado.

El modelo Holt-Winters también deteriora el *benchmark*, con $U = 2,241$. Este desempeño se atribuye a que el suavizamiento exponencial no captura adecuadamente la dinámica irregular del empleo agrícola tras el período COVID-19.

Finalmente, el ensemble ponderado, con $U = 1,223$, tampoco supera al naïve. Su desempeño se ve afectado negativamente por la contribución del VECM, al que asigna un peso cercano a

cero. En particular, los pesos estimados son $\hat{\alpha}_{\text{HW}} = 0,509$, $\hat{\alpha}_{\text{SARIMA}} = 0,659$, $\hat{\alpha}_{\text{ctrl}} = -0,167$ y $\hat{\alpha}_{\text{VECM}} = -0,001$. Estos pesos suman uno, como exige la restricción del método.

4.3. Test de Diebold-Mariano

La Tabla 2 presenta los resultados de la prueba formal de comparación predictiva para seis pares de modelos. El estadístico DM es negativo cuando el modelo de la columna “Modelo 1” genera errores menores que el modelo de la columna “Modelo 2”. Por tanto, un valor significativo y negativo indica superioridad estadística del Modelo 1.

Tabla 2: Test de Diebold-Mariano: comparaciones extendidas

Comp.	Modelo 1	vs	Modelo 2	Media d_t	DM stat	p -valor
A	SARIMA base	vs	Holt-Winters	-39876.6	-5.844***	0.0000
B	SARIMA base	vs	VAR/VECM	-17293.0	-3.701***	0.0007
C	SARIMA base	vs	OCMT-SARIMA	0.0	—	—
D	SARIMA base	vs	Ensemble G-R B	-8141.4	-3.091***	0.0039
E	VAR/VECM	vs	OCMT-SARIMA	17293.0	3.701***	0.0007
F	OCMT-SARIMA	vs	Ensemble G-R B	-8141.4	-3.091***	0.0039

Nota: $d_t = e_{M1}^2 - e_{M2}^2$. Errores Newey-West con 3 rezagos. La hipótesis nula es igualdad de precisión predictiva. La comparación C arroja un estadístico DM indeterminado porque OCMT-SARIMA es idéntico al SARIMA base. *** $p < 0,01$, ** $p < 0,05$, * $p < 0,10$.

Las comparaciones (A), (B) y (D) confirman la superioridad estadística del SARIMA base al 1 %. Frente a Holt-Winters, el estadístico DM es $-5,844$, con $p < 0,001$; frente al VECM, el SARIMA base también resulta significativamente superior, con $p = 0,0007$; y frente al ensemble ponderado mantiene una ventaja estadísticamente significativa, con $p = 0,0039$. Estos resultados descartan que la relación de cointegración de largo plazo se traduzca en una ganancia predictiva de corto plazo y muestran que la combinación lineal de pronósticos no necesariamente mejora el desempeño cuando algunos modelos componentes presentan errores sistemáticamente altos.

La comparación (E) confirma simétricamente que el SARIMA base, vía OCMT, supera al VECM. La Figura 1 del Anexo ilustra visualmente estas diferencias: el SARIMA base sigue con mayor fidelidad el patrón estacional observado, mientras que el VECM diverge sistemáticamente hacia valores superiores y el ensemble amplifica los errores de sus modelos componentes deficientes.

5. Conclusiones

Los resultados de este trabajo confirman y extienden el hallazgo del análisis anterior: el modelo SARIMA(1,1,1)(1,1,1)₁₂, estimado exclusivamente sobre la dinámica interna del empleo agrícola, constituye el mejor predictor entre los ocho enfoques comparados.

La incorporación de información adicional no mejora el desempeño predictivo en el horizonte

mensual analizado. Esto ocurre tanto cuando la información se incorpora mediante regresores externos en modelos SARIMA como cuando se introduce mediante la relación de cointegración con el capital físico en el VECM, la selección de variables macroeconómicas por OCMT o la combinación lineal de pronósticos.

El resultado más llamativo es que el procedimiento OCMT, aplicado a un conjunto de 15 indicadores macroeconómicos de alta frecuencia, no seleccionó ninguna variable como predictor relevante de los cambios en el empleo agrícola. Esto equivale a una validación empírica de que la estructura interna de la serie es suficiente para capturar su dinámica de corto plazo.

El VECM, aunque fundamentado en una relación de cointegración estadísticamente válida, produce pronósticos de corto plazo inferiores incluso al naïve estacional. Este resultado ilustra la brecha entre relevancia económica de largo plazo e información predictiva de corto plazo.

Una interpretación unificada de estos hallazgos es que el empleo agrícola en Estados Unidos está dominado, en frecuencia mensual, por su patrón estacional y por su estructura de persistencia de corto plazo. Estas fuentes de variación se capturan de manera parsimoniosa mediante el SARIMA base. Las variables macroeconómicas externas, incluyendo el capital físico, parecen operar en horizontes más largos y no anticipan adecuadamente las fluctuaciones mensuales.

Finalmente, el estudio también tiene algunas limitaciones que deben tenerse en cuenta. Por un lado, el horizonte de evaluación se restringe a 36 meses, por lo que los resultados reflejan el desempeño predictivo de los modelos en una ventana específica de tiempo. Por otro lado, los resultados del procedimiento OCMT dependen de la forma en que se define el conjunto activo de variables candidatas. En ese sentido, futuras extensiones podrían evaluar horizontes múltiples de pronóstico e incorporar variables de alta frecuencia más directamente relacionadas con condiciones climáticas y agrícolas específicas.

6. Anexos

6.1. Tabla de pruebas ADF

Tabla 3: Pruebas ADF: orden de integración

Variable	Niveles		Δ regular		Δ estacional	
	$Z(t)$	p	$Z(t)$	p	$Z(t)$	Conclusión
ln(empleo ag.)	-2,102	0.545	-7,452***	0.000	-7,716***	I(1)
ln(inv. maq.)	-3,053	0.118	-4,482***	0.002	-6,729***	I(1)
ln(PPI agr.)	-2,892	0.165	-4,541***	0.001	-6,520***	I(1)
ln(sal. mín.)	-2,024	0.588	-2,459	0.349	-4,631***	I(1)

Nota: Prueba ADF con tendencia y 12 rezagos. Valores críticos con tendencia: 1 % = -3,99; 5 % = -3,43; 10 % = -3,13. H_0 : raíz unitaria. *** $p < 0,01$, ** $p < 0,05$, * $p < 0,10$.

6.2. Variables del conjunto activo OCMT

Tabla 4: Variables del conjunto activo OCMT: 15 candidatos

Código FRED	Descripción	Categoría	Forma
A33ATI	Inventarios maquinaria agrícola	Capital	$L_1\Delta \ln$
WPU01	PPI productos agrícolas	Precios ag.	$L_1\Delta \ln$
FEDMINFRMWG	Salario mínimo agrícola	Costos lab.	$L_1\Delta \ln$
PAYEMS	Empleo total no agrícola	Mercado lab.	$L_1\Delta \ln$
UNRATE	Tasa de desempleo	Mercado lab.	$L_1\Delta$
CPIAUCSL	IPC general	Precios macro	$L_1\Delta \ln$
PPIACO	PPI todos los commodities	Precios macro	$L_1\Delta \ln$
FEDFUNDS	Tasa fondos federales	Monetario	$L_1\Delta$
GS10	Bono del Tesoro 10 años	Financiero	$L_1\Delta$
T10Y2Y	Spread curva 10Y-2Y	Financiero	$L_1\Delta$
M2SL	Masa monetaria M2	Monetario	$L_1\Delta \ln$
DCOILWTICO	Precio petróleo WTI	Insumos	$L_1\Delta \ln$
INDPRO	Producción industrial	Actividad real	$L_1\Delta \ln$
HOUST	Inicios de construcción	Uso del suelo	$L_1\Delta \ln$
RSXFS	Ventas minoristas ex-gas.	Demanda interna	$L_1\Delta \ln$

Nota: Fuente: FRED (Federal Reserve Bank of St. Louis 2026). La forma $L_1\Delta \ln$ indica rezago 1 de la primera diferencia del logaritmo; $L_1\Delta$ indica rezago 1 de la primera diferencia en niveles. La variable dependiente en OCMT es $\Delta\Delta_{12} \ln(\text{empleo})$.

6.3. Figuras




Figura 1: Pronósticos fuera de muestra: modelos clave con corrección B-O

Nota: La línea roja vertical marca el inicio del período de evaluación, correspondiente a octubre de 2022. Las líneas discontinuas muestran pronósticos en niveles con corrección Beauchamp-Olson. El período 2019–2022 muestra el ajuste *in-sample* de los modelos SARIMA y OCMT, que coinciden. El VECM solo genera pronósticos dinámicos fuera de muestra.




Figura 2: Pronósticos fuera de muestra: todos los modelos con corrección B-O

Nota: La línea roja vertical marca el inicio del período de evaluación, correspondiente a octubre de 2022. Todos los pronósticos están expresados en miles de personas con corrección Beauchamp-Olson (Beauchamp y Olson 1973).

7. Referencias

- Beauchamp, J. J. y J. S. Olson (1973). “Corrections for bias in regression estimates after logarithmic transformation”. En: *Ecology* 54.6, págs. 1403-1407.
- Chudik, Alexander, George Kapetanios y M. Hashem Pesaran (2018). “A one covariate at a time, multiple testing approach to variable selection in high-dimensional linear regression models”. En: *Econometrica* 86.4, págs. 1479-1512.
- Diebold, Francis X. y Roberto S. Mariano (1995). “Comparing predictive accuracy”. En: *Journal of Business & Economic Statistics* 13.3, págs. 253-263.
- Federal Reserve Bank of St. Louis (2026). *FRED: Federal Reserve Economic Data*. URL: <https://fred.stlouisfed.org/>.
- Granger, Clive W. J. y Ramu Ramanathan (1984). “Improved methods of combining forecasts”. En: *Journal of Forecasting* 3.2, págs. 197-204.
- Gutiérrez Arango, Antonio (2026). “Pronósticos de empleo agrícola en Estados Unidos: Una evaluación del poder predictivo mediante modelos de series de tiempo”. Facultad de Economía, Universidad del Rosario.
- Hamilton, James D. (1994). *Time Series Analysis*. Princeton University Press.
- Hamilton, Stephen F., Timothy J. Richards y Aric P. Shafran (2020). “The impact of mechanization on agricultural markets: Evidence and implications”. En: *Annual Review of Resource Economics* 12, págs. 123-145.
- Harvey, David, Stephen Leybourne y Paul Newbold (1997). “Testing the equality of prediction mean squared errors”. En: *International Journal of Forecasting* 13.2, págs. 281-291.
- Holt, Charles C. (2004). “Forecasting seasonals and trends by exponentially weighted moving averages”. En: *International Journal of Forecasting* 20.1, págs. 5-10.
- Hyndman, Rob J. y George Athanasopoulos (2018). *Forecasting: Principles and Practice*. 2nd. Melbourne, Australia: OTexts.
- Levendis, John D. (2018). *Time Series Econometrics: Learning Through Replication*. Cham: Springer.
- Núñez, Héctor M. y Jesús Otero (2021). “A one covariate at a time, multiple testing approach to variable selection in high-dimensional linear regression models: A replication in a narrow sense”. En: *Journal of Applied Econometrics* 36.6, págs. 833-841.
- USDA Economic Research Service (2022). *Agricultural Productivity in the United States*. URL: <https://www.ers.usda.gov/data-products/agricultural-productivity-in-the-us/>.