

Pronósticos del empleo agrícola en Estados Unidos

Una comparación extendida entre modelos univariados, multivariados y de alta dimensión

Antonio Gutiérrez Arango

Facultad de Economía
Universidad del Rosario

Mayo 2026

Motivación

- ▶ La producción agrícola de EE.UU. se **triplicó** en los últimos 60 años.^a
- ▶ El empleo agrícola cayó cerca de **76 %** en el mismo período.
- ▶ La mecanización sustituye trabajo y eleva la productividad del trabajo restante.^b
- ▶ Pronosticar el empleo agrícola mensual es relevante para política laboral rural, asignación de recursos y planeación productiva.

^a USDA Economic Research Service (2022).

^b Hamilton, Richards y Shafran (2020).



Pregunta central

¿Qué enfoque predictivo captura mejor la dinámica mensual del empleo agrícola?

Primera entrega

- ▶ Se compararon 5 modelos: naïve, Holt-Winters y tres SARIMA.
- ▶ Pregunta: ¿el capital físico mejora el pronóstico?
- ▶ Resultado: el SARIMA base fue el mejor modelo.
- ▶ Diebold-Mariano confirmó superioridad al 5 %.^a

^a Gutiérrez Arango (2026).

Segunda entrega

- ▶ Se incorporan tres enfoques adicionales:
 - VECM.
 - OCMT.
 - Ensemble ponderado.
- ▶ Total: **8 modelos comparados**.
- ▶ Evaluación fuera de muestra: 36 meses.

Fuente: FRED (Federal Reserve Bank of St. Louis 2026) — frecuencia mensual.

Período: enero 2000 – septiembre 2025 ($n = 309$).

Partición:

- ▶ **Train:** 2000m1 – 2022m9 ($T = 273$)
- ▶ **Test:** 2022m10 – 2025m9 ($h = 36$)

Variable dependiente:

Empleo agrícola EE.UU. (LNU02034560)

Miles de personas; media = 2,278; rango: [1,889; 2,718].

Variables exógenas — SARIMA:


- ▶ WPU01: PPI productos agrícolas
- ▶ FEDMINFRMWG: salario mínimo agrícola
- ▶ A33ATI: inventarios maquinaria (capital físico)

Conjunto activo — OCMT (15 variables):

- ▶ Mercado laboral, precios macro, monetario/financiero, actividad real, insumos energéticos.
- ▶ Forma: $L_1 \Delta \ln(\cdot)$ o $L_1 \Delta(\cdot)$ para tasas.


I(1) confirmada: prueba ADF con tendencia y 12 rezagos para las 4 series originales.

Serie observada: estacionalidad y tendencia



La serie exhibe estacionalidad marcada, tendencia decreciente de largo plazo y cambios relevantes después de 2020.

Identificación SARIMA: correlogramas



El patrón de ACF/PACF de $\Delta\Delta_{12} \ln y_t$ apoya la especificación $\text{SARIMA}(1, 1, 1)(1, 1, 1)_{12}$.

Marco metodológico: ocho modelos

#	Modelo	Tipo	Información empleada
1	Naïve estacional	Benchmark	Valor del mismo mes del año anterior, y_{t-12} .
2	Holt-Winters	Suavizamiento	Nivel, tendencia y estacionalidad.
3	SARIMA base	Univariado	Dinámica interna del empleo agrícola.
4	SARIMA + controles	SARIMA-X	PPI agrícola y salario mínimo agrícola.
5	SARIMA completo	SARIMA-X	Controles más capital físico contemporáneo y rezagado.
6	VECM	Multivariado	Empleo agrícola y capital físico bajo cointegración.
7	OCMT-SARIMA	Alta dimensión	Selección automática entre 15 variables macroeconómicas.
8	Ensemble G-R B	Combinado	Promedio ponderado de modelos individuales.

Todos los pronósticos en logaritmos se retransforman a niveles mediante la corrección Beauchamp-Olson.¹

¹ Beauchamp y Olson (1973).

Modelo 1: Naïve estacional

Ecuación

$$\hat{y}_t = y_{t-12}$$

- ▶ Usa como pronóstico el valor observado del mismo mes del año anterior.
- ▶ Captura la estacionalidad anual básica.
- ▶ Funciona como *benchmark* mínimo de comparación.

Modelo 2: Holt-Winters multiplicativo

Estructura general

$$\ell_t = \alpha \frac{y_t}{S_{t-m}} + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

$$S_t = \gamma \frac{y_t}{\ell_t} + (1 - \gamma)S_{t-m}$$

- ▶ Se estima sobre $\ln y_t$.
- ▶ Captura nivel, tendencia y estacionalidad.
- ▶ Es equivalente a una estructura multiplicativa en niveles.

Modelo SARIMA

$$\Phi(B^{12})\phi(B)\Delta^d\Delta_{12}^D \ln y_t = \Theta(B^{12})\theta(B)\varepsilon_t$$

- Especificación seleccionada: SARIMA(1, 1, 1)(1, 1, 1)₁₂.
- Se estima únicamente con la dinámica interna del empleo agrícola.
- No incluye regresores externos.
- Es el modelo central de comparación.

Modelo 4: SARIMA con controles

Modelo SARIMA-X

$$\Phi(B^{12})\phi(B)\Delta^d\Delta_{12}^D \ln y_t = \beta_1 x_{1t} + \beta_2 x_{2t} + \Theta(B^{12})\theta(B)\varepsilon_t$$

- ▶ Mantiene la estructura SARIMA(1, 1, 1)(1, 1, 1)₁₂.
- ▶ Añade dos regresores externos:
 - PPI agrícola.
 - Salario mínimo agrícola.
- ▶ Evalúa si los controles macrosectoriales mejoran el pronóstico.

Modelo 5: SARIMA completo

Modelo con capital físico

$$\Phi(B^{12})\phi(B)\Delta^d\Delta_{12}^D \ln y_t = \mathbf{x}_t'\boldsymbol{\beta} + \Theta(B^{12})\theta(B)\varepsilon_t$$
$$\mathbf{x}_t = [\ln(\text{PPI}_t), \ln(\text{salario}_t), \ln(\text{capital}_t), L_1 \ln(\text{capital}_t), L_2 \ln(\text{capital}_t)]$$

- ▶ Incorpora capital físico contemporáneo y rezagado.
- ▶ Permite evaluar si la maquinaria agrícola aporta información predictiva adicional.

Modelo vectorial de corrección de errores

$$\Delta y_t = \Pi y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta y_{t-i} + \varepsilon_t$$
$$y_t = \begin{pmatrix} \ln(\text{empleo}_t) \\ \ln(\text{capital}_t) \end{pmatrix}$$

- ▶ La prueba de Johansen confirma cointegración con $r = 1$.²
- ▶ Rezago óptimo: $p = 4$, seleccionado por SBIC.
- ▶ Evalúa si la relación de largo plazo mejora el pronóstico de corto plazo.

² Levendis (2018).

Modelo 7: OCMT-SARIMA

Procedimiento OCMT

$$\Delta\Delta_{12} \ln y_t = \alpha + \sum_{j=1}^4 \rho_j L_j \Delta\Delta_{12} \ln y_t + \gamma_i L_1 \Delta x_{i,t} + u_t$$

- ▶ Se evalúan 15 variables macroeconómicas candidatas.³
- ▶ Variable dependiente: $\Delta\Delta_{12} \ln y_t$.
- ▶ Variables preseleccionadas: rezagos 1–4 de la dependiente.
- ▶ Parámetros: $\delta = 1$, $\delta^* = 2$ y $p = 5\%$.
- ▶ Resultado: ninguna variable externa seleccionada.

Implicación

OCMT-SARIMA termina siendo algebraicamente equivalente al SARIMA base.

³ Chudik, Kapetanios y Pesaran (2018); Núñez y Otero (2021).

Modelo 8: Ensemble ponderado

Combinación de pronósticos

$$\hat{y}_t^{ens} = \sum_{j=1}^J \alpha_j \hat{y}_{j,t} \quad \text{sujeto a} \quad \sum_{j=1}^J \alpha_j = 1$$

- ▶ Sigue el Método B de Granger y Ramanathan (1984).⁴
- ▶ Los pesos se estiman por mínimos cuadrados restringidos.
- ▶ Combina Holt-Winters, SARIMA base, SARIMA con controles y VECM.

$$\hat{\alpha}_{HW} = 0,509, \quad \hat{\alpha}_{SARIMA} = 0,659, \quad \hat{\alpha}_{ctrl} = -0,167, \quad \hat{\alpha}_{VECM} = -0,001$$

⁴ Granger y Ramanathan (1984).

Problema de retransformación

$$\mathbb{E}[\exp(\hat{y}^{\ln} + \varepsilon)] \neq \exp(\hat{y}^{\ln})$$

Corrección

$$\hat{y}_t^{BO} = \exp(\hat{y}_t^{\ln}) \times \exp\left(\frac{\hat{\sigma}^2}{2}\right)$$

- ▶ Evita la subestimación generada por exponenciar directamente.⁵
- ▶ Permite comparar todos los pronósticos en niveles.
- ▶ Se aplica antes de calcular RMSE, MAPE y Theil U .

⁵ Beauchamp y Olson (1973).

$$\text{RMSE} = \sqrt{\frac{1}{h} \sum_{t=1}^h e_t^2}$$

$$\text{MAPE} = \frac{1}{h} \sum_{t=1}^h \left| \frac{e_t}{y_t} \right| \times 100$$

$$\text{Theil } U = \frac{\text{RMSE}_{\text{modelo}}}{\text{RMSE}_{\text{naïve}}}$$

- ▶ $U < 1$: supera al naïve.
- ▶ $U = 1$: igual al naïve.
- ▶ $U > 1$: peor que el naïve.

Diferencial de pérdida

$$d_t = e_{1t}^2 - e_{2t}^2$$

Estadístico

$$DM = \frac{\bar{d}}{s_{\bar{d}}} \stackrel{a}{\sim} \mathcal{N}(0, 1)$$

- ▶ H_0 : igualdad de precisión predictiva.⁶
- ▶ Se usan errores estándar Newey-West.
- ▶ Rezagos: $h = \lfloor 36^{1/3} \rfloor = 3$.
- ▶ Si $DM < 0$ y es significativo, el Modelo 1 supera al Modelo 2.


⁶ Diebold y Mariano (1995); Harvey, Leybourne y Newbold (1997).

Resultados: métricas de precisión predictiva

Modelo	RMSE	MAPE (%)	Theil U
Naïve estacional	94.86	3.38	1.000
Holt-Winters	212.61	8.83	2.241
SARIMA base	72.97	2.48	0.769
SARIMA + controles	76.93	2.70	0.811
SARIMA completo	76.10	2.67	0.802
VAR/VECM	150.39	5.92	1.585
OCMT-SARIMA	72.97	2.48	0.769
Ensemble G-R B	116.04	4.40	1.223

Nota: RMSE en miles de personas. El SARIMA base obtiene el menor RMSE, el menor MAPE y el menor Theil U .


Pronósticos: todos los modelos



Línea roja: inicio período test (2022m10). Pronósticos en niveles B-O.

Línea roja: inicio del período test en octubre de 2022. Pronósticos en niveles con corrección B-O.

Pronósticos: modelos clave



Línea roja: inicio período test (2022m10). Pronósticos en niveles B-O.

El SARIMA base y el OCMT-SARIMA coinciden. El VECM diverge hacia valores superiores al nivel observado.

Test de Diebold-Mariano

Comp.	Modelo 1	vs	Modelo 2	Media d_t	DM	p
A	SARIMA base	vs	Holt-Winters	-39 877	-5.844***	0.0000
B	SARIMA base	vs	VAR/VECM	-17 293	-3.701***	0.0007
C	SARIMA base	vs	OCMT-SARIMA	0	—	—
D	SARIMA base	vs	Ensemble G-R B	-8 141	-3.091***	0.0039
E	VAR/VECM	vs	OCMT-SARIMA	+17 293	+3.701***	0.0007
F	OCMT-SARIMA	vs	Ensemble G-R B	-8 141	-3.091***	0.0039

$DM < 0$ indica que el Modelo 1 genera menor pérdida cuadrática. *** $p < 0,01$.^a

^a Diebold y Mariano (1995).

Resultado principal

El SARIMA base supera significativamente a Holt-Winters, VECM y Ensemble al 1 %.

- ① El **SARIMA base** es el mejor predictor entre los ocho modelos comparados.
- ② La incorporación de regresores externos no mejora el desempeño predictivo.
- ③ El OCMT no selecciona variables externas, lo que valida la parsimonia del SARIMA base.
- ④ La cointegración de largo plazo entre empleo y capital no se traduce en ganancia predictiva mensual.
- ⑤ El empleo agrícola parece estar dominado por estacionalidad y persistencia de corto plazo.

Referencias I

-  Beauchamp, J. J. y J. S. Olson (1973). "Corrections for bias in regression estimates after logarithmic transformation". En: *Ecology* 54.6, págs. 1403-1407.
-  Chudik, Alexander, George Kapetanios y M. Hashem Pesaran (2018). "A one covariate at a time, multiple testing approach to variable selection in high-dimensional linear regression models". En: *Econometrica* 86.4, págs. 1479-1512.
-  Diebold, Francis X. y Roberto S. Mariano (1995). "Comparing predictive accuracy". En: *Journal of Business & Economic Statistics* 13.3, págs. 253-263.
-  Federal Reserve Bank of St. Louis (2026). *FRED: Federal Reserve Economic Data*. URL: <https://fred.stlouisfed.org/>.
-  Granger, Clive W. J. y Ramu Ramanathan (1984). "Improved methods of combining forecasts". En: *Journal of Forecasting* 3.2, págs. 197-204.
-  Gutiérrez Arango, Antonio (2026). "Pronósticos de empleo agrícola en Estados Unidos: Una evaluación del poder predictivo mediante modelos de series de tiempo". *Facultad de Economía, Universidad del Rosario*.

Referencias II

-  Hamilton, Stephen F., Timothy J. Richards y Aric P. Shafran (2020). "The impact of mechanization on agricultural markets: Evidence and implications". En: *Annual Review of Resource Economics* 12, págs. 123-145.
-  Harvey, David, Stephen Leybourne y Paul Newbold (1997). "Testing the equality of prediction mean squared errors". En: *International Journal of Forecasting* 13.2, págs. 281-291.
-  Levendis, John D. (2018). *Time Series Econometrics: Learning Through Replication*. Cham: Springer.
-  Núñez, Héctor M. y Jesús Otero (2021). "A one covariate at a time, multiple testing approach to variable selection in high-dimensional linear regression models: A replication in a narrow sense". En: *Journal of Applied Econometrics* 36.6, págs. 833-841.
-  USDA Economic Research Service (2022). *Agricultural Productivity in the United States*. URL: <https://www.ers.usda.gov/data-products/agricultural-productivity-in-the-us/>.